




DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Aprendizaje Automático

2026-2c

Clase 1:
Administrativos
Introducción a Aprendizaje Automático



Hoy

- Objetivos, correlatividades, evaluación, bibliografía.
- Presentación del contenido de toda la materia.
- Primera clase teórica (aprendizaje supervisado).
- Chequeo de correlativas (hoy o jueves)

Aprendizaje Automático - 3er bimestre 2026

Horario y lugar: 17:00 a 21:00. **Aula 2** (Pabellón 1)

Campus virtual: <https://campus.exactas.uba.ar/course/view.php?id=1363>

Importante: Tienen que estar **matriculados** en la materia. La comunicación será a través del **campus virtual**.

- **2 puntos** de optativa para **Licenciatura en Computación (plan 93)**.
- **64 créditos** para **Licenciatura en Computación (plan 2023)**.
- **64 horas** para **Licenciatura en Ciencia de Datos**.
- **2 puntos** para **Licenciatura en Física (combo 2 + 3 si hacen las dos)**.
- **3 puntos** para **el Doctorado en Computación (combo 3 + 2 si hacen las dos)**.



Cecilia Bolaños (Ay1)



Martín García Solá (Ay1)



Martín Meza (JTP)



Pablo Brusco (Prof)

Dinámica de la materia

- **Clases teóricas.** Generalmente subiremos las diapos instantes antes de la clase.
- **Guías prácticas:** Cada tema tendrá asociada una guía práctica que subiremos al campus al finalizar la teórica del tema.
- **Clases prácticas:** Durante cada clase práctica trabajaremos con los ejercicios de las guías. Se recomienda fuertemente ir al día con las guías.
- **Parciales:** Los armaremos suponiendo que hicieron las guías y siguieron las teóricas.
- **Notebooks:** Serán publicados junto con los cuestionarios asociados.
- **Lecturas obligatorias semanales:** Aprox 1 cap. de un libro por semana.
- **Cuestionarios obligatorios:** Semanalmente habrá cuestionarios en formato de google forms sobre la clase, los notebooks y las lecturas obligatorias. Por defecto, tendrán poco más de 1 semana para resolverlos. Ej, si se presentan el martes luego de la clase, tendrán tiempo hasta el miércoles de la siguiente a noche.

Régimen de Aprobación (vale para las dos bimestrales)

- Para aprobar la cursada deben aprobar el **parcial**, el **TP**, leer la **bibliografía obligatoria** que se presenta al final de cada clase y **completar los cuestionarios semanales obligatorios**.
- Se puede **promocionar** obteniendo nota 7 o superior, aprobando el TP, participando de la competencia del TP y habiendo aprobado **5 de los 6 cuestionarios**.
- Para quienes **recuperen** un parcial (habiéndolo aprobado o no), la nota que cuenta es la del recuperatorio.
- Quienes obtengan nota inferior a 7 el parcial deben dar el **final**.

Fechas

TP-AA1:

- Presentación Jue **27 /08**
- Primera Entrega: Mar **15 /09**
- Entrega final: Jue **24 /09**
- Peer Review: Mar **29 /09**

Parcial-AA1:

- Fecha: Jue **01 /10**
- Recu 1: Mar **01 /12**

TP-AA2 (tentativas)

- Presentación Mar **06 /10**
- Entrega Dom **22/11**
- Presentación alumnos: Mar **24 /11**

Parcial-AA2:

- Fecha: Mar **17 /11**
- Recu: Jue **03 /12**

inscripciones AA2

[28 /09 - 04/10]

Aprendizaje Automático I





Optativa del Departamento de Computación.

Objetivos de la materia:

Una **introducción abarcativa** de los principales **conceptos, decisiones algorítmicas** y **efectos** de distintos **métodos** de aprendizaje automático.

Correlativas:

- **Computación plan 93:** Proba, Metnum y Algo III.
- **Computación plan 23:** Estadística, Ingeniería.
- **Ciencia de Datos:** Estadística, ALC y Algo III.
- **Física:** Labo 5, Teórica 3 y Cálculo Numérico (recomendable haber hecho Métodos Estadísticos para Física Experimental).




Bibliografía (AA1):

- James, Witten, Hastie & Tibshirani, **An Introduction to Statistical Learning with Applications in Python**, Springer, 2023. PDF y recursos: <https://www.statlearning.com/>
- Mitchell, **Machine Learning**, McGraw-Hill, 1997. [PDF escaneado](#) | [PDF original](#)
- Müller & Guido, **Introduction to Machine Learning with Python**, O'Reilly, 2016. [PDF](#)
- Hastie, Tibshirani & Friedman, **The Elements of Statistical Learning**, 2nd ed, Springer, 2009. [PDF](#)

Herramientas



[Home](#) [Installation](#) [Documentation](#) [Examples](#) [Search](#) ×



scikit-learn

Machine Learning in Python

- Simple and efficient tools for data mining and data analysis
- Accessible to everybody, and reusable in various contexts
- Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable - BSD license

Classification

Identifying to which category an object belongs to.

Applications: Spam detection, Image recognition.

Algorithms: SVM, nearest neighbors, random forest, ... [— Examples](#)

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.

Algorithms: SVR, ridge regression, Lasso, ... [— Examples](#)

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, ... [— Examples](#)

Dimensionality reduction

Reducing the number of random variables to consider.

Applications: Visualization, Increased efficiency

Algorithms: PCA, feature selection, non-negative matrix factorization. [— Examples](#)

Model selection

Comparing, validating and choosing parameters and models.

Goal: Improved accuracy via parameter tuning

Modules: grid search, cross validation, metrics. [— Examples](#)

Preprocessing

Feature extraction and normalization.

Application: Transforming input data such as text for use with machine learning algorithms.

Modules: preprocessing, feature extraction. [— Examples](#)

Programa (AA 1)

- Aprendizaje de **conceptos**
- **Evaluación y selección** de modelos
- **Sesgo y Varianza**
- **Clasificadores Generativos y Discriminativos**: Árboles, KNN, Naive Bayes, LDA, SVM, logística.
- **Ensamblados**: Bagging, Random Forest, Boosting
- **Clustering**: K-Means, GMM, algoritmo EM, clustering jerárquico aglomerativo, DBSCAN
- **Métricas** y evaluación de clasificadores probabilísticos
- **Ingeniería de atributos**

Introducción

¿Qué debería saber después de esta clase?

- Def Problemas de aprendizaje bien planteados
- Aprendizaje supervisado:
 - Modelos / Hipótesis
 - Espacio de Atributos
 - Espacio de Hipótesis
 - Espacio de Instancias
 - Fronteras de decisión
 - Clasificación vs Regresión
 - LLMs como APIs para clasificación y regresión.
 - Navaja de Ockham.
 - Sustento del Aprendizaje Inductivo.
 - Aprendizaje automático como un problema de búsqueda.
 - Generalización: Sobreajuste, subajuste.
 - Sesgo inductivo

Tip: Atento/as a las alertas

Clave N: ... esparcidas por las clase

Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada un texto que describe un objeto mi living, ¿es una silla?

Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?

Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



Algunos problemas...

- ¿N es múltiplo de 2022?
- ¿N es primo?
- Encontrar el máximo en una lista.
- Ubicar 8 reinas en un tablero y que no se ataquen.
- Ubicar antenas de radio para lograr que no haya interferencias.
- Dados 100.000.000 de tweets, ¿cuántos nombran a Messi?
- Dada una descripción de un objeto mi living, ¿es una silla?



¿Qué pasó?

¿Qué materia me perdí?

¿Qué pasó?

¿Qué materia me perdí?

Hay problemas con **reglas** tan **complejas** que no podemos atacarlos con programación clásica...

(ni con la ayuda de LLMs... ya veremos...)

Parte 1

Nociones básicas de
Aprendizaje Automático

Definición: “Problemas de aprendizaje bien planteados”

[Mitchell Sec. 1.1]

Un programa se dice que aprende a partir de la **experiencia E** con respecto a una **tarea T** y una medida de **performance P**, si su performance en la **tarea T**, medida **mediante P**, mejora con la **experiencia E**.

Ejemplos:

T: Reconocimiento del habla.

P: *Distancia de edición* entre transcripción real y predicha en llamados reales.

E: Una base de datos de conversaciones entre agentes de call-centers y clientes junto a su transcripción.

T: Manejo autónomo en calles reales.

P: Distancia recorrida hasta el primer error.


E: Sensores en el volante, pedales y cámaras mientras maneja un humano.

T: Jugar al Ajedrez.


P: Porcentaje de juegos ganados online contra competidores humanos.

E: Jugar contra sí mismo.

Queremos un sistema que ...




"Silla"




No "Silla"


Queremos un sistema que ...



Queremos un sistema que ...




Queremos un sistema que ...



Queremos un sistema que ...



A veces vamos a querer construir “regresores”




Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores/regresores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso




Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores/regresores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso




Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores/regresores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso




Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores/regresores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso



Simplificación! ya veremos que el pipeline es más complejo...

Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores/regresores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso



Simplificación! ya veremos que el pipeline es más complejo...

Aprendizaje supervisado

Recolección de datos



Instancias
(ejemplos)



Atributos
(features)

Etiqueta

Atributos (features)			Etiqueta
PESO	COLOR	#PATAS	¿Es Silla?
3.4	Marrón	3	Sí
10.2	Varios	2	No
4.5	Verde	4	No
5.2	???	4	Sí
3.2	Marrón	3	No
...	...	...	...

Aprendizaje supervisado

Recolección de datos



Instancias
(ejemplos)

Atributos
(features)

Etiqueta

PESO	COLOR	#PATAS	¿Es Silla?
3.4	Marrón	3	Sí
10.2	Varios	2	No
4.5	Verde	4	No
5.2	???	4	Sí
3.2	Marrón	3	No
...	...	...	...

Aprendizaje supervisado

Recolección de datos



Instancias
(samples)

1

2

3

Atributos
(features)

Etiqueta
(labels)


Atributos (features)			Etiqueta (labels)
PESO	COLOR	#PATAS	¿Es Silla?
3.4	Marrón	3	Sí
10.2	Varios	2	No
4.5	Verde	4	No
5.2	???	4	Sí
3.2	Marrón	3	No
...	...	...	...

Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores/regresores de manera **automática**. Tres pasos fundamentales.

Primer paso



Segundo paso



Tercer paso



Aprendizaje supervisado

Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



PESO	COLOR	#PATAS	Siila?
3.4	Marrón	3	Si
10.2	Varios	2	No
4.5	Verde	4	No
5.2	???	4	Si
3.2	Marrón	3	No
...	...	...	...



Lleno de reglas



Aprendizaje supervisado

Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



PESO	COLOR	#PATAS	Siila?
3.4	Marrón	3	Si
10.2	Varios	2	No
4.5	Verde	4	No
5.2	???	4	Si
3.2	Marrón	3	No
...	...	...	...



Lleno de reglas



Aprendizaje supervisado

Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



PESO	COLOR	#PATAS	Siila?
3.4	Marrón	3	Sí
10.2	Varios	2	No
4.5	Verde	4	No
5.2	???	4	Sí
3.2	Marrón	3	No
...	...	...	...



Lleno de reglas



Aprendizaje supervisado

Entrenar un clasificador



Un clasificador puede ser pensado como una caja de reglas...

Vacía al principio



PESO	COLOR	#PATAS	Siila?
3.4	Marrón	3	Sí
10.2	Varios	2	No
4.5	Verde	4	No
5.2	???	4	Sí
3.2	Marrón	3	No
...	...	...	...



Lleno de reglas



```
def es_silla(x):  
    return False
```

Caja vacía



```
def es_silla(x):  
    if (x.patas < 2 && x.peso < 0.3):  
        return True  
  
    if (x.patas > 3 && x.peso < 4.3):  
        if (x.peso > 2.3 && x.patas == 4):  
            return True  
        else:  
            return False  
  
    if (x.peso > 1000):  
        return False  
    else:  
        if x.color != 3:  
            return False  
        else:  
            if x.peso > 500:  
                ...  
    ...
```

Caja vacía + Datos = Caja con reglas



```

def es_silla(x):
    if (x.patas < 2 && x.peso < 0.3):
        return True

    if (x.patas > 3 && x.peso < 4.3):
        if (x.peso > 2.3 && x.patas == 4):
            return True
        else:
            return False


    if (x.peso > 1000):
        return False
    else:
        if x.color != 3:
            return False
        else:
            if x.peso > 500:
                ...
            ...

```

Caja vacía + Datos = Caja con reglas

Reglas que NO programaremos

Habrà algún algoritmo que las genere por nosotros




Aprendizaje supervisado



Nombre de la técnica que se utiliza para **construir** los clasificadores/regresores de manera **automática**. Tres pasos fundamentales.


Primer paso



Segundo paso



Tercer paso




Aprendizaje supervisado

Hacer predicciones



Instancia nunca antes vista

DESCRIPCIÓN	
PESO	6.2 KG
COLOR	Negro
#PATAS	4




Aprendizaje supervisado

Hacer predicciones



Instancia nunca antes vista

DESCRIPCIÓN	
PESO	6.2 KG
COLOR	Negro
#PATAS	4




Aprendizaje supervisado

Hacer predicciones



Instancia nunca antes vista

DESCRIPCIÓN	
PESO	6.2 KG
COLOR	Negro
#PATAS	4



Silla!

97%

En muchos casos produciendo un puntaje (o score) asociado.

Parte 2



¿Qué es lo que pasa realmente?

Concepto importantísimo para hoy y en el resto de la materia.


¿Cómo se piensan los “atributos”?

Atributos (features en inglés)

PESO	4.2 KG
#PATAS	3
MATERIAL	Madera
Silla	

PESO	2 KG
#PATAS	0
MATERIAL	Vidrio
Maceta	

(Peso, #Patas, Material)



PESO	9 KG
#PATAS	4
MATERIAL	??
Mesa	

PESO	10 KG
#PATAS	3
MATERIAL	Vidrio
Mesa	

¿Cómo se piensan los “atributos”?

Atributos (features en inglés)

PESO	4.2
#PATAS	3
MATERIAL	1
Silla	

PESO	2
#PATAS	0
MATERIAL	2
Maceta	

(Peso, #Patas, Material)




PESO	9
#PATAS	4
MATERIAL	0
Mesa	

PESO	10
#PATAS	3
MATERIAL	2
Mesa	

¿Cómo se piensan los “atributos”?


Atributos (features en inglés)

Clave 1: Pensando instancias como vectores en $\mathbb{R}^p$




¿Qué pinta tiene un clasificador?

Modelo 1 (construido con Algoritmo L_1)



Espacio de Atributos ($\mathbb{R}^3$)

Modelo 2 (construido con Algoritmo L_2)




Espacio de Atributos ($\mathbb{R}^3$)

¿Qué pinta tiene un clasificador?

Modelo 1 (construido con Algoritmo L_1)

¿Cómo lo programo?




No se programan,

- Se decide la forma.
- Se programa la infraestructura.
- Se **entrena**^(*), **valida** y **evalúa**.

(*) Veremos que entrenar no es siempre necesario.

¿Qué pinta tiene un clasificador?


Modelo (Ejemplo - Atributos en $\mathbb{R}^2$)



Ejemplo: Algoritmo que iterativamente va generando estas “**fronteras de decisión**” (regiones del espacio de atributos asignados a una clase o la otra, en este caso 2 regiones, la roja y la azul)

¿Qué pinta tiene un clasificador?

Modelo (Ejemplo - Atributos en $\mathbb{R}^2$)



Ejemplo: Algoritmo que iterativamente va generando estas “**fronteras de decisión**” (regiones del espacio de atributos asignados a una clase o la otra, en este caso 2 regiones, la roja y la azul)

¿Predecir? Una vez que algoritmo convergió (las fronteras de decisión quedan definidas)

Podemos asignar una clase a una instancia nueva, en este caso  será clasificada como clase azul.

Garbage in - Garbage out


¡Una mala elección de atributos puede hacer el problema mucho más complejo/imposible! **¿Por qué?**

Clave 2: ¿Qué información necesita un humano para predecir?

¿Está disponible esa información en mis instancias?

Viendo esta imagen, ¿qué clasificador proponen?

(Peso, #Patas, Material)




Espacio de Atributos
(atributos en $\mathbb{R}^3$)

Garbage in - Garbage out


¡Una mala elección de atributos puede hacer el problema mucho más complejo/imposible! **¿Por qué?**

(Peso, Color, #Ruedas)




Espacio de Atributos
(atributos en $\mathbb{R}^3$)

(Peso, #Patas, Material)



Espacio de Atributos
(atributos en $\mathbb{R}^3$)

(Material, #Ojos, #Ruedas)



Espacio de Atributos
(atributos en $\mathbb{R}^3$)


Aprendizaje Supervisado: Terminología

Función objetivo: Estamos interesados en modelar un **proceso particular**; queremos aprender o aproximar una **función que no conocemos**, pero de la cual **tenemos ejemplos**.

Hipótesis: Una cierta **función que construimos y creemos** (o esperamos que sea) similar a la función objetivo que queremos modelar. La crearemos utilizando el algoritmo **L**

Modelo: En el campo del aprendizaje automático, los términos hipótesis y modelo a menudo se usan indistintamente.

Ojo: a veces “modelo” también se utiliza para referirse al algoritmo de aprendizaje. Trataremos de evitar esta acepción.



Ejemplo

Problema: predecir el TIPO de vivienda en alquiler publicada en alguna plataforma.

Instancias: Viviendas, representadas por sus mts^2 , $\#baños$ y precio .

Etiquetas: $\{PH, DEPTO, CASA\}$. (suponemos que no hay otra cosa)

$X=R^{??}$

$Y=??$

$D=??$

$f^*=??$

Juguemos un segundos con ser L , dar un ejemplo de $f_{L,D}$.


$L=??$

$f_{L,D}=??$

Nota (Clave 3): ¿Y si el dataset tiene **2 instancias iguales, con distintas etiquetas?**

Ej: Un *PH* y una *CASA* con $\langle m^2=130, \#baños=2, \text{precio}=700k \rangle$

- ¿Quiere decir que ya no es **función** lo que estamos aproximando?
- Ya veremos más adelante cómo se piensa estos casos.
- Por ahora suponer que no sucede



Ejemplo extendido

Tarea: Predecir el tipo de vivienda publicada

Atributos

- **Superficie** (m²) :: Int {1, ..., 500}
- **Precio** (USD/mes) :: Int {100, ..., 3000}
- **Ambientes** :: Int {1, ..., 6}
- **Baños** :: Int {1, ..., 4}
- ¿**Tiene patio?** :: Bool {Sí, No}
- ¿**Tiene expensas?** :: Bool {Sí, No}

Etiqueta:

- **Tipo** :: Enum {PH, DEPTO, CASA}

Aprendizaje Inductivo

ID	Superficie (m²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Función objetivo: ?? (desconocida)

Hipótesis H_1 : Si *Expensas* = *sí*, predice **DEPTO**. Si *Expensas* = *no*, predice **CASA**.

Aprendizaje Inductivo

ID	Superficie (m²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Función objetivo: ?? (desconocida)

Hipótesis H_1 : Si *Expensas* = *sí*, predice **DEPTO**. Si *Expensas* = *no*, predice **CASA**.

Accuracy H_1 (exactitud): ? (#veces que acertamos en estos datos si utilizamos **H_1** dividido el total de instancias)

Aprendizaje Inductivo

ID	Superficie (m²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Función objetivo: ?? (desconocida)

Hipótesis H_1 : Si *Expensas* = *sí*, predice **DEPTO**. Si *Expensas* = *no*, predice **CASA**.

Accuracy H_1 (exactitud): **58.3%** (7/12)

¿Qué opinan de esta solución?

Aprendizaje Inductivo

ID	Superficie (m²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Función objetivo: ?? (desconocida)

Hipótesis H_2 : Si $Sup \in \{55, 60, 85, 110\} \Rightarrow$ PH, Si $Sup \in \{150, 180, 220\} \Rightarrow$ CASA, si no DEPTO

Accuracy H_2 (exactitud): ??

Aprendizaje Inductivo

ID	Superficie (m²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Función objetivo: ?? (desconocida)

Hipótesis H_2 : Si $Sup \in \{55, 60, 85, 110\} \Rightarrow$ PH, Si $Sup \in \{150, 180, 220\} \Rightarrow$ CASA, si no DEPTO

Accuracy H_2 (exactitud): 100% (12/12)

¿Qué opinan de esta solución?

Aprendizaje Inductivo

ID	Superficie (m ²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Función objetivo: ?? (desconocida)

Hipótesis H_3 : si $Sup \geq 145 m^2$ y $Patio = sí \Rightarrow$ **CASA**, si $Patio = sí$ y $Expensas = no \Rightarrow$ **PH**, si no **DEPTO**.

Accuracy H_3 : (exactitud): ??

Aprendizaje Inductivo

ID	Superficie (m²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Función objetivo: ?? (desconocida)

Hipótesis H_3 : si $Sup \geq 145 m^2$ y $Patio = sí \Rightarrow CASA$, si $Patio = sí$ y $Expensas = no \Rightarrow PH$, si no **DEPTO**.

Accuracy H_3 : (exactitud): **91.7%** (11 / 12)

¿Qué opinan de esta solución?

Generalización





Queremos un modelo lo **suficientemente rico** para captar ideas complejas. Pero sin caer en:

Subajuste (underfitting)

Construcción de un modelo **demasiado simple** que no capture la información disponible.

Sobreajuste (overfitting)

Construcción de un **modelo demasiado complejo** para la cantidad de información que disponemos.



Müller, A. C., & Guido, S. (2016). Introduction to machine learning with Python: a guide for data scientists.

Además, queremos encontrar reglas que funcionen para **nuevos** ejemplos. No para los que ya conocemos su respuesta. Veremos más adelante que la forma principal de medir cómo funciona un modelo será evaluando las predicciones sobre un **conjunto "nuevo" de datos**.

Generalización

Para intentar formalizar un poco estos conceptos, podemos utilizar las siguientes definiciones basadas en [1]

Se desea aprender una función objetivo $\mathbf{f}^*$ **desconocida** mediante un conjunto finito de datos de entrenamiento $\mathbf{D} = \{(\mathbf{x}^{(i)}, \mathbf{y}^{(i)})\}_{i=1}^n$, una muestra de la distribución real (y de nuevo.. desconocida) de los datos.

Decimos que $\mathbf{h}_{L,D}$, un modelo construido usando el algoritmo $\mathbf{L}$ sobre $\mathbf{D}$ **subajusta** si:

$$(\exists h' : H) Err_{train}(h_{L,D}) \geq Err_{train}(h') \wedge Err_{true}(h_{L,D}) > Err_{true}(h')$$

Análogamente, $\mathbf{h}_{L,D}$ **sobreajusta** si:

$$(\exists h' : H) Err_{train}(h_{L,D}) \leq Err_{train}(h') \wedge Err_{true}(h_{L,D}) > Err_{true}(h')$$

En donde

$$Err_{train}(h) = \frac{1}{|D|} \sum_{(x^{(i)}, y^{(i)}) \in D} error(h(x^{(i)}), y^{(i)})$$

$$Err_{true}(h) = \mathbb{E}_x[error(h(x), y)] = \int error(h(x), y) P(x, y) dx$$

¿De dónde sale y?

Ya veremos más adelante que $\mathbf{y}^{(i)} \approx \mathbf{f}^*(\mathbf{x}^{(i)})$

¿Y qué es error(A, B)?

Depende del problema y del tipo de problema (reg, clasif, etc)

Modelos Simples

En general queremos encontrar el modelo que cumpla el siguiente principio:

Navaja de Ockham

(un principio metodológico y filosófico).

Cuando tenemos dos modelos que compiten, **producen las mismas predicciones**, debemos elegir el más simple.

Un modelo más simple es aquel que tiene menos parámetros o menor complejidad estructural.

¿Por qué?

En la práctica se ve que ayuda a:

- **Evitar el sobreajuste** y por lo tanto mejorar el rendimiento en datos no vistos.
- **Mejora la interpretación:** Los modelos más simples son más fáciles de interpretar y entender.
- **Reduce los costos** computacionales.

Aprendizaje Inductivo

ID	Superficie (m²)	Precio (USD)	Ambientes	Baños	¿Tiene patio?	¿Tiene expensas?	Tipo (Etiqueta Real)
1	35	320	1	1	no	sí	DEPTO
2	50	450	2	1	no	sí	DEPTO
3	75	700	3	1	no	sí	DEPTO
4	90	850	3	2	no	sí	DEPTO
5	140	1400	4	2	no	sí	DEPTO
6	60	500	2	1	sí	no	PH
7	85	750	3	1	sí	no	PH
8	110	950	4	2	sí	no	PH
9	55	480	2	1	no	no	PH
10	180	1600	5	3	sí	no	CASA
11	220	2100	5	3	sí	no	CASA
12	150	1350	4	2	sí	sí	CASA

Hipótesis H_1 : Si *Expensas* = *sí*, predice **DEPTO**. Si *Expensas* = *no*, predice **CASA**.

¿Cuál es el tamaño del **Espacio de Hipótesis**? (cuántos modelos posibles se pueden construir)

¿Cuál es el tamaño del **Espacio de Instancias**? (cuántas instancias posibles existen)

Sustento del Aprendizaje Inductivo

Veamos cuántas posibilidades hay para cada atributo suponiendo que cada atributo puede tener:

- Superficie: 300 valores posibles
- Precio: 100 valores
- Ambientes: 6 valores
- Baños: 4 valores
- ¿Tiene patio?: 2 valores
- ¿Tiene expensas?: 2 valores

El **espacio de instancias X** contiene exactamente: $300 \times 100 \times 6 \times 4 \times 2 \times 2$ elementos.

$|X| = 1.440.000$

El **espacio de hipótesis** (cuántos modelos posibles se pueden construir) contiene:

$3^{1.440.000}$ posibles elementos (subconjuntos de X)

Sustento del Aprendizaje Inductivo

Cualquier **hipótesis (o modelo)** que aproxime bien a la **función objetivo** sobre un conjunto **suficientemente grande de ejemplos** de entrenamiento, también **aproximará bien** a la función objetivo sobre otros **ejemplos no observados^(a)**.

Si vemos el aprendizaje como un **problema de búsqueda**, necesitamos diferentes estrategias para buscar y evaluar distintos modelos en el espacio de hipótesis.

Nota (Clave 4): Nos interesan **algoritmos capaces de buscar eficientemente** espacios de hipótesis **muy grandes o infinitos**, para encontrar las hipótesis que **“mejor”** se ajusten a los datos^(b).

(a) [Mitchell 2.2.2 “THE INDUCTIVE LEARNING HYPOTHESIS”]

(b) [Mitchell 2.3 “CONCEPT LEARNING AS SEARCH”]


Clasificación vs. Regresión

Clasificación

- Se busca predecir un valor perteneciente a un conjunto finito, sin orden. "Etiquetas"
- **Ejs:** ¿Spam? ¿idioma de un sitio web? ¿Tumor maligno? ¿Cambiará de compañía telefónica? ¿Dígito nombrado?

Regresión

- Busca predecir un valor cuantitativo (enteros, reales, etc).
- Hay continuidad en las posibles salidas.
- **Ejs:** ¿Sueldo de una persona? ¿Gasto en publicidad para el año siguiente? ¿Temperatura del viernes?



Classification

¿Soleado, nublado o lluvioso?




Regression

¿Temperatura media mañana?



Clasificación vs. Regresión



Clasificación

$\text{output}^{(i)} :: \text{Bool} \mid \text{Enum}$

- Se busca predecir un valor perteneciente a un conjunto finito, sin orden. "Etiquetas"
- **Ejs:** ¿Spam? ¿idioma de un sitio web? ¿Tumor maligno? ¿Cambiará de compañía telefónica? ¿Dígito nombrado?



Classification

¿Soleado, nublado o lluvioso?



Regresión

$\text{output}^{(i)} :: \mathbb{N} \mid \mathbb{Z} \mid \mathbb{R} \mid \mathbb{R}^d$

- Busca predecir un valor cuantitativo (enteros, reales, etc).
- Hay continuidad en las posibles salidas.
- **Ejs:** ¿Sueldo de una persona? ¿Gasto en publicidad para el año siguiente? ¿Temperatura del viernes?



Regression

¿Temperatura media mañana?



Clasificación

Ejemplo con atributos continuos

Imaginemos que tenemos que predecir si una persona saldrá a caminar o no según la temperatura y la humedad del día.

- **Temperatura:** $\mathbb{R} [-50, 80]$
- **Humedad:** $\mathbb{R} [0, 100]$


Por lo tanto, crearemos la función **Caminar** quedaría:

Caminar : Temperatura x Humedad $\rightarrow \{\text{Sí}, \text{No}\}$

Por lo que empezamos por juntar datos, registramos el comportamiento del vecino durante unas semanas y armamos el siguiente gráfico.

¿Qué modelo se les ocurre?

Visualización de los datos en el espacio de atributos (color = clase)



Regresión

Ejemplo con atributos continuos

Ahora imaginemos estimar el precio de venta de una vivienda según

X_1 = los metros cuadrados cubiertos,


X_2 = su distancia al centro de la ciudad.


Y = **precio de una casa**

Nota: Otros atributos podrían haber sido la *cantidad de visitas al sitio de publicación* y el *color de la pintura*, el *nombre de la calle*, etc. Es decir, los atributos siguen teniendo la propiedad de ser atributos continuos, categóricos, nominales, etc, pero cambia lo que queremos predecir lo cual es determinado por **las etiquetas asociadas**.

¿Qué modelo se les ocurre?


Visualización de los datos en el espacio de atributos (color+label = valor a predecir)





Ejemplo de modelo: Los colores de cada región representan valores numéricos que se asignaría a cualquier instancia que caiga en esa región, ej, **Violeta = \$88k**

Algunas subcategorías (de clasificación)



En caso de tratarse de outputs posibles entre **{True, False}** decimos **"Clasificación Binaria"**


Ej: Este tweet, ¿**es** ofensivo o **no lo es**?

En caso de tratarse de outputs entre **{Clase1, Clase2, Clase3, ...}** decimos **"Clasificación Multiclase"**

Ej: ¿Cuál es el animal principal (entre **{Perro, Gato, Ratón}**) en este audio?

En caso de tener más de una etiqueta por instancia, decimos **"Clasificación Multi-Etiqueta"**

Ej: ¿Qué Beatles (entre **{George, Paul, Ringo, John}**) aparecen en esta imagen?



APIs de LLMs como predictores

Mencionamos la necesidad de recolectar datos anotados

(costoso, lento, difícil) ... **pero ya estamos en 2026...** ¿Hace falta entrenar estos modelos? ¿Hace falta aprender patrones de los datos?

Bueno, hay alternativas. Un patrón muy común es “pegarle” a una **API** de (por ej) **Gemini** (comercial) / **Gemma** (local) / **Claude** (comercial) / **GPT** (comercial) / etc. Muy muy utilizadas en la industria.

Zero-Shot / Prototipado rápido: Permite tener un clasificador/regresor en producción en minutos sin juntar miles de instancias D etiquetadas.

- No requiere entrenamiento previo ni ingeniería de atributos manual.
- Entiende contexto semántico complejo sin reglas rígidas.

```
class PrediccionVivienda(BaseModel):
    tipo: Literal["DEPTO", "PH", "CASA"]
    confianza: float

def to_string(x_i):
    con_sin_patio = "con" if x_i["patio"] else "sin"
    con_sin_expensas = "con" if x_i["expensas"] else "sin"
    return f'{x_i["mts2"]} mts^2, {x_i["ambientes"]} ambientes, {con_sin_patio} patio, {con_sin_expensas} expensas'

client = genai.Client()

prompt = f"Clasifica esta vivienda: {to_string(x_i)}."

response = client.models.generate_content(
    model='gemini-2.5-flash',
    contents=prompt,
    config={'response_schema': PrediccionVivienda}
)

print(response.text)
# Output: {"tipo": "PH", "confianza": 0.95}
```

APIs de LLMs como predictores

Mencionamos la necesidad de recolectar datos anotados (costoso, lento, difícil) ... **pero ya estamos en 2026...** ¿Hace falta entrenar estos modelos? ¿Hace falta aprender patrones de los datos?

Bueno, hay alternativas. Un patrón muy común es “pegarle” a una **API** de (por ej) **Gemini** (comercial) / **Gemma** (local) / **Claude** (comercial) / **GPT** (comercial) / etc. Muy muy utilizadas en la industria.

WARNING!

- En mi experiencia, esto es “útil”, pero potencialmente **una trampa!** (anécdota tesis Tomás, Florencia)
- ¿Y entonces, cómo sé si funcionará o no?

Clave 6: Las técnicas para medir performance y tener confianza en las soluciones **es casi idéntica a la de los modelos clásicos. ¡Y muy pocos las utilizan en la industria!**

```
class PrediccionVivienda(BaseModel):
    tipo: Literal["DEPTO", "PH", "CASA"]
    confianza: float

def to_string(x_i):
    con_sin_patio = "con" if x_i["patio"] else "sin"
    con_sin_expensas = "con" if x_i["expensas"] else "sin"
    return f'{x_i["mts2"]} mts^2, {x_i["ambientes"]} ambientes, {con_sin_patio} patio, {con_sin_expensas} expensas'

client = genai.Client()

prompt = f"Clasifica esta vivienda: {to_string(x_i)}."

response = client.models.generate_content(
    model='gemini-2.5-flash',
    contents=prompt,
    config={'response_schema': PrediccionVivienda}
)

print(response.text)
# Output: {"tipo": "PH", "confianza": 0.95}
```

Sesgo inductivo

Sesgo Inductivo

Un **conjunto finito** de datos nunca alcanza para **inferir** un único modelo. Es por ello que tenemos que agregar supuestos.

Definición: Sesgo Inductivo

Considere un algoritmo de aprendizaje L para el dominio X . Sean

f^* una función arbitraria (generalmente desconocida) definida sobre X .

$D = \{(x^{(i)}, f^*(x^{(i)}))\}_{i=1}^N$ un conjunto arbitrario de ejemplos de entrenamiento (o dataset).

$f_{L,D}(x^{(i)})$ la clasificación asignada a la instancia $x^{(i)}$ por $f_{L,D}$ (una función que aproxima a f^*) construida utilizando L sobre los datos D .

Dada cualquier instancia del dominio X , llamémosla x , el **sesgo inductivo** del algoritmo L es cualquier conjunto mínimo de afirmaciones B tal que para cualquier función objetivo f^* y los ejemplos de entrenamiento de D , se puede deducir el valor $f_{L,D}(x)$ (la predicción de la instancia x que haría el modelo resultante de entrenar a L con D).

Mitchell lo sintetiza como:

$$(\forall x \in X)[(B \wedge D \wedge x) \vdash f_{L,D}(x)]$$

En otras palabras: **Conjunto de supuestos** que el algoritmo de aprendizaje integra al modelo que, sumado a los datos de entrenamiento, permite conocer las predicciones que hará el modelo sobre cualquier dato (vito o no visto anteriormente).

Estos supuestos pueden provenir de una variedad de fuentes, incluyendo:

- Estructura del modelo
- La función que el algoritmo esté optimizando
- Características de funcionamiento del algoritmo (cómo recorre el espacio de hipótesis hasta elegir un único modelo, la semilla random utilizada, etc)
- etc

El sesgo inductivo determina los **tipos de funciones** que el algoritmo **puede aprender** y los **tipos de errores** que un modelo construido con este **se espera que cometa**.

Algoritmo de aprendizaje: L

Función objetivo

$f^* : X \rightarrow Y$

(desconocida)

Ejemplos de entrenamiento

$D = \{ \langle x^{(i)}, f^*(x^{(i)}) \rangle \}$

Algoritmo de

aprendizaje: L

Hipótesis ó

Modelo:

$f_{L,D} : X \rightarrow Y$

Espacio de hipótesis

(muy grandes o infinito)

Espacio restringido por **Sesgo inductivo** del algoritmo L

Espacio restringido por los **datos de entrenamiento D**

Opciones exploradas
(cómputo / tiempo)

$f_{L,D}$

Distancia a la función objetivo
(error de aproximación)

★
 f^*


Resumen

- Introdujimos los distintos tipos de aprendizaje automático.
- Hablamos de la diferencia entre **aprendizaje automático** y **aprendizaje estadístico**.
- Introdujimos la diferencia entre **clasificación** y **regresión**.
- Vimos como un **LLM** puede ser utilizado para estas tareas.
- Definimos:
 - Función objetivo
 - Hipótesis / Modelo.
 - Generalización, Overfitting, Underfitting.
 - Espacio de Hipótesis e Instancias.
 - Navaja de Ockham.
 - Sustento del Aprendizaje Inductivo.
 - Aprendizaje automático como un problema de búsqueda.
 - Sesgo Inductivo.

Próximo tema: primeros modelos predictivos, Árboles de Decisión.

TAREA

- A) Leer Capítulo 1 del Machine Learning for Predictive Data Analytics (Kelleher)
- B) Leer **Secciones 2.1 a 2.8 inclusive** del "Machine Learning" (Mitchell) . [Descargar](#)
- C) Completar el **Notebooks 01** (Herramientas) y **02** (Titanic).
- D) Completar el **Cuestionario**.
- E) Armar grupos (5 personas) (pronto enviaremos un form). Tienen tiempo hasta el **jueves 18**
- F) Mirar este video para la próxima: <https://www.youtube.com/watch?v=YtebGVx-Fxw>



Tom Mitchell